

CURSO: A.I - Classificadores

INFORMAÇÕES DO DESAFIO Grupo: 14

Domínio: Saúde

Tipo: Classificação Binária

Dataset Kaggle: uciml/breast-cancer-wisconsin-data

DESAFIO 14: CLASSIFICAÇÃO DE CÂNCER DE MAMA

1 INTRODUÇÃO E ANÁLISE EXPLORATÓRIA (EDA)

Este relatório detalha o desenvolvimento do desafio 14 de um classificador para o diagnóstico de câncer de mama, utilizando o *dataset Breast Cancer Wisconsin*. O objetivo principal é distinguir entre tumores benignos e malignos com base em características morfológicas das células.

A análise exploratória revelou um *dataset* íntegro, composto por 569 amostras e 30 atributos preditores. A distribuição das classes apresenta 62,7% de casos benignos e 37,3% malignos. Através da visualização de *boxplots*, identificou-se que as características de tumores malignos tendem a apresentar médias e valores máximos significativamente superiores, especialmente nos atributos relacionados ao tamanho e irregularidade do núcleo celular.

2 PRÉ-PROCESSAMENTO E METODOLOGIA

Para garantir a eficácia dos modelos, foram aplicadas as seguintes etapas de preparação:

- **Limpeza:** Remoção de colunas não informativas (ID) e tratamento de dados inconsistentes.
- **Normalização:** Aplicação de *StandardScaler* para garantir que todos os modelos (especialmente lineares e SVM) operem na mesma escala, evitando distorções por ordens de magnitude.
- **Divisão de Dados:** Particionamento estratificado em treino (40%), validação (30%) e teste (30%).
- **Seleção de Atributos:** Utilização do teste ANOVA (*SelectKBest*) para isolar as 15 variáveis com maior poder preditivo.

3 COMPARAÇÃO DE CLASSIFICADORES (RESULTADOS DE TESTE)

A tabela abaixo consolida o desempenho dos modelos no conjunto de teste final, garantindo a avaliação sobre dados nunca vistos durante o treinamento.

Tabela 1 - Resultados de desempenho dos classificadores no conjunto de teste

Classificador	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	9.474	9.655	8.889	9.256	9.893
Random Forest	9.415	9.818	8.571	9.153	9.854
SVM	9.298	1.2000	8.095	8.947	9.880

4 ANÁLISE COMPARATIVA E DISCUSSÃO

4.1 Qual modelo teve melhor desempenho?

A Regressão Logística (*Logistic Regression*) foi o modelo com melhor desempenho global. Apresentou a maior acurácia (94,74%) e o maior *F1-Score* (0,9256), indicando o equilíbrio mais robusto entre Precisão e *Recall*. Sua curva ROC (AUC de 0,9893) demonstra uma capacidade superior de discriminação entre as classes em comparação aos demais algoritmos testados.

4.2 *Feature Importance*: Indicadores de malignidade

A análise estatística identificou que as medições do tipo "*worst*" (piores valores encontrados) são as mais discriminativas. As características que mais fortemente indicam malignidade são:

- ***Concave points_worst***: Reflete a gravidade das deformações no contorno celular.
- ***Perimeter_worst* / *Radius_worst***: Indicam o crescimento desordenado e o tamanho do núcleo.

Biologicamente, isso indica que tumores malignos tendem a apresentar células não apenas maiores em dimensão, mas principalmente com formatos mais irregulares e deformados.

4.3 Discussão clínica: Falso positivo vs. Falso negativo

Em diagnósticos de câncer, o custo dos erros é assimétrico. Um Falso Positivo gera ansiedade e custos com biópsias desnecessárias, mas um Falso Negativo é fatal, pois interrompe o tratamento de uma doença agressiva e em progressão.

A análise da matriz de confusão mostra que o SVM, embora preciso, gerou 12 Falsos Negativos. A Regressão Logística reduziu esse erro crítico para apenas 7 casos (alcançando o maior *Recall*), tornando-se a escolha mais segura do ponto de vista clínico. O modelo prioriza a detecção (sensibilidade), garantindo que o menor número possível de pacientes doentes fique sem o suporte médico necessário.